

Klasifikasi Tingkat Kematangan Daun Ketapang (*Terminalia catappa*) Menggunakan Metode Transfer Learning dengan Arsitektur MobileNetV2

Classification of Maturity Level of Ketapang Leaves (Terminalia catappa) Using Transfer Learning Method with MobileNetV2 Architecture

1st Ariel Maulana

Fakultas Ilmu Terapan
Universitas Telkom
Bandung, Indonesia
arielmaulanaam@student.telkomuiversity.ac.id

2nd Dwi Farrel Elfarindu

Fakultas Ilmu Terapan
Universitas Telkom
Bandung, Indonesia
dwifarrelfarindu@student.telkomuniversitas.ac.id

3rd Muhammad Zharfan Al Ghifari

Fakultas Ilmu Terapan
Universitas Telkom
Bandung, Indonesia
muhammadzharfanal@student.telkomuniversitas.ac.id

Abstrak — Tingkat kematangan daun ketapang (*Terminalia catappa*) memengaruhi kandungan senyawa aktif di dalamnya, namun identifikasi manual melalui pengamatan visual masih bersifat subjektif dan kurang efisien. Penelitian ini mengusulkan sistem klasifikasi citra digital menggunakan metode *transfer learning* berbasis arsitektur MobileNetV2 yang efisien secara komputasi. Dataset yang digunakan terdiri dari sekitar 2.400 citra yang dibagi ke dalam tiga kelas: daun muda, menguning, dan tua, dengan menerapkan tahapan augmentasi untuk meningkatkan generalisasi model. Hasil pengujian menunjukkan model mampu mencapai tingkat akurasi sebesar 95,42%, didukung oleh performa *precision*, *recall*, dan *F1-score* yang tinggi serta konsisten di seluruh kelas. Dengan demikian, penerapan MobileNetV2 terbukti menjadi solusi yang efektif dan handal untuk klasifikasi kematangan daun ketapang secara otomatis.

Kata Kunci: daun ketapang, *transfer learning*, MobileNetV2, klasifikasi citra, *deep learning*.

Abstract — The maturity level of ketapang leaves (*Terminalia catappa*) affects their active compound content, yet manual identification via visual observation remains subjective and inefficient. This study proposes a digital image classification system using a transfer learning method based on the computationally efficient MobileNetV2 architecture. The dataset comprises approximately 2,400 images categorized into three classes: young, yellowing, and old leaves, incorporating data augmentation steps to enhance model generalization. The test results show that the model achieves an accuracy of 95.42%, supported by high and consistent precision, recall, and F1-score across all classes. Consequently, the application of MobileNetV2

proves to be an effective and reliable solution for automated ketapang leaf maturity classification.

Keywords: ketapang leaf, transfer learning, MobileNetV2, image classification, deep learning.

I. PENDAHULUAN

Perkembangan *deep learning*, khususnya arsitektur *Convolutional Neural Network* (CNN), telah membawa perubahan signifikan dalam otomatisasi pengenalan pola visual. Teknologi ini banyak diadopsi untuk menggantikan proses identifikasi manual di berbagai sektor, termasuk pengolahan citra komoditas hayati. Salah satu objek yang potensial untuk dikembangkan adalah daun ketapang (*Terminalia catappa*). Daun dari tanaman tropis ini kaya akan senyawa bioaktif seperti flavonoid, tanin, dan polifenol yang berguna sebagai antioksidan serta antibakteri. Karena kadar senyawa aktif tersebut sangat dipengaruhi oleh fase pertumbuhan daun, identifikasi tingkat kematangan menjadi parameter krusial untuk menentukan kualitas pemanfaatannya.

Namun, penentuan kematangan daun ketapang saat ini umumnya masih mengandalkan pengamatan visual manusia. Metode konvensional ini memiliki keterbatasan karena sifatnya yang subjektif, sangat bergantung pada pengalaman personal pengamat, serta rentan keliru akibat variasi pencahayaan. Di samping itu, penyortiran manual memerlukan waktu lama dan kurang efisien jika diterapkan pada skala besar.

Untuk mengatasi kendala tersebut, pemanfaatan citra digital dikombinasikan dengan metode *transfer learning* menawarkan solusi yang menjanjikan. Melalui *transfer learning*, model dapat memanfaatkan bobot (*weights*) yang telah terlatih dari *dataset* berskala besar seperti ImageNet. Pendekatan ini terbukti efektif menghasilkan akurasi optimal dan mempercepat

konvergensi pelatihan, sekalipun ukuran *dataset* lokal yang digunakan relatif terbatas [1].

Dalam penelitian ini, arsitektur MobileNetV2 dipilih sebagai basis klasifikasi. MobileNetV2 memiliki keunggulan pada struktur *inverted residuals* dan *linear bottlenecks* yang membuatnya mampu menghasilkan akurasi tinggi dengan beban komputasi dan jumlah parameter yang minimal [2]. Karakteristik tersebut sangat ideal untuk skenario implementasi perangkat dengan sumber daya komputasi terbatas.

Berdasarkan latar belakang tersebut, penelitian ini berfokus pada pengembangan sistem klasifikasi tingkat kematangan daun ketapang yang dibagi ke dalam tiga kelas utama: daun muda, menguning, dan tua. Tujuan utamanya adalah membangun model klasifikasi berbasis MobileNetV2, mengevaluasi performanya melalui metrik akurasi, *precision*, *recall*, dan *F1-score*, serta menganalisis sejauh mana efektivitas *transfer learning* dalam mengoptimalkan klasifikasi pada data citra daun ketapang [2]. Hasil penelitian ini diharapkan dapat menyediakan metode identifikasi kematangan daun yang lebih cepat, objektif, dan konsisten.

II. KAJIAN TEORI

A. *Terminalia catappa* L. (Daun Ketapang)

Terminalia catappa atau ketapang merupakan tanaman tropis yang banyak ditemukan di wilayah Asia Tenggara. Tanaman ini memiliki daun berukuran lebar dengan bentuk oval dan mengalami perubahan warna yang cukup jelas selama proses pertumbuhannya. Perubahan warna tersebut umumnya dimulai dari hijau pada fase muda, berubah menjadi kuning pada fase transisi, dan menjadi cokelat kemerahan pada fase tua [3].

Karakteristik perubahan warna tersebut menjadikan daun ketapang sebagai objek yang sesuai untuk penelitian klasifikasi citra berbasis kecerdasan buatan. Perbedaan visual antar tingkat kematangan dapat diamati melalui variasi warna, tekstur permukaan, dan pola distribusi pigmen daun.

Dalam penelitian ini, daun ketapang diklasifikasikan ke dalam tiga kategori

utama, yaitu daun muda, daun menguning, dan daun tua. Ketiga kategori tersebut digunakan sebagai kelas target dalam proses pelatihan model klasifikasi citra berbasis deep learning [4].

B. Pengolahan Citra Digital

Pengolahan citra digital merupakan proses pemanfaatan teknik komputasi untuk memperoleh informasi dari suatu gambar digital. Dalam bidang computer vision, citra direpresentasikan sebagai matriks piksel yang menyimpan informasi warna dan intensitas cahaya.

Pada penelitian ini, citra daun ketapang digunakan sebagai masukan utama untuk sistem klasifikasi. Sebelum diproses oleh model deep learning, citra terlebih dahulu melalui tahap preprocessing yang meliputi penyesuaian ukuran gambar menjadi 224×224 piksel serta normalisasi nilai piksel menggunakan fungsi `preprocess_input` sesuai standar arsitektur MobileNetV2.

Selain preprocessing, diterapkan pula teknik augmentasi data untuk meningkatkan keragaman data pelatihan. Augmentasi dilakukan melalui transformasi seperti rotasi, pembalikan citra, perubahan tingkat kecerahan, perubahan kontras, dan zoom. Teknik ini bertujuan meningkatkan kemampuan generalisasi model serta mengurangi risiko overfitting selama proses pelatihan.

C. Transfer Learning

Transfer learning merupakan metode pembelajaran mesin yang memanfaatkan pengetahuan dari model yang telah dilatih sebelumnya pada dataset berskala besar untuk menyelesaikan permasalahan baru yang memiliki karakteristik serupa. Pendekatan ini banyak digunakan pada bidang klasifikasi citra karena mampu menghasilkan performa yang baik meskipun jumlah data pelatihan relatif terbatas [5].

Pada penelitian ini digunakan model MobileNetV2 yang telah dilatih menggunakan dataset ImageNet sebagai sumber pengetahuan awal. Bobot hasil pelatihan tersebut dimanfaatkan sebagai representasi fitur dasar sebelum dilakukan proses penyesuaian terhadap dataset daun ketapang.

Strategi transfer learning yang digunakan adalah partial fine-tuning, yaitu membuka kembali sebagian lapisan akhir model untuk dilatih ulang menggunakan data penelitian. Pendekatan ini memungkinkan model

beradaptasi terhadap karakteristik visual daun ketapang tanpa kehilangan kemampuan ekstraksi fitur yang telah dipelajari sebelumnya.

D. *Convolutional Neural Network (CNN) dan Arsitektur Deep Learning*

Convolutional Neural Network (CNN) adalah kelas khusus dari artificial neural network yang dirancang untuk memproses data dengan struktur grid-like, seperti citra dua dimensi. CNN memanfaatkan operasi konvolusi untuk mengekstrak fitur lokal dari input dan membangun representasi hierarkis dari fitur kompleks [6]. Struktur dasar CNN terdiri dari beberapa jenis layer.

Convolutional Layer: Layer ini menerapkan operasi konvolusi menggunakan filter (kernel) kecil yang digeser di seluruh citra input. Setiap filter belajar mendeteksi pola lokal spesifik. Output dari convolutional layer disebut feature map.

Activation Function : Fungsi aktivasi *Rectified Linear Unit (ReLU)*, yang didefinisikan sebagai $f(x) = \max(0, x)$, diterapkan setelah konvolusi untuk memperkenalkan nonlinearitas. ReLU telah menjadi fungsi aktivasi standar dalam deep learning karena efisiensi komputasinya. *Pooling Layer:* Layer ini melakukan downsampling untuk mengurangi dimensi feature map sambil mempertahankan informasi penting. Max pooling, yang mengambil nilai maksimum dari region lokal, adalah teknik pooling paling umum.

Fully Connected Layer: Layer ini menghubungkan semua neuron dari layer sebelumnya ke layer saat ini. *Fully connected layer* biasanya digunakan di akhir network untuk *classification tasks*.

E. Arsitektur MobileNetV2

MobileNetV2 adalah arsitektur neural network yang dirancang khusus untuk efisiensi tinggi pada perangkat mobile dan edge dengan keterbatasan komputasi. Arsitektur ini menggabungkan beberapa inovasi kunci: (1) Depthwise Separable Convolution: mengurangi jumlah parameter dengan memisahkan konvolusi spasial dari konvolusi lintas-channel; (2) Inverted Residual Blocks: menggunakan ekspansi fitur yang diikuti kontraksi untuk efisiensi; (3) Linear Bottleneck: menghapus nonlinearitas di output bottleneck untuk melestarikan informasi [7].


Secara kuantitatif, MobileNetV2 mencapai

akurasi top-1 71.3% pada ImageNet dengan hanya 3.5 juta parameter, dibandingkan dengan ResNet yang memerlukan parameter jauh lebih banyak. Latensi inferensi MobileNetV2 juga signifikan lebih rendah, membuatnya cocok untuk aplikasi real-time. Dalam konteks plant disease detection dan plant leaf classification, studi-studi terbaru menunjukkan bahwa MobileNetV2 memberikan trade-off yang sangat baik antara akurasi dan efisiensi komputasi.

MobileNetV2 dipilih karena memiliki jumlah parameter yang relatif kecil dibandingkan arsitektur CNN modern lainnya. Dengan sekitar 3,5 juta parameter, MobileNetV2 mampu menghasilkan performa klasifikasi yang tinggi dengan kebutuhan komputasi yang lebih rendah. Karakteristik tersebut menjadikan MobileNetV2 sesuai untuk implementasi pada perangkat dengan sumber daya terbatas serta aplikasi klasifikasi citra secara real-time.

III. METODE

A. Desain Sistem



Gambar 3.1 Desain Sistem

Desain sistem pada penelitian ini menggambarkan alur proses klasifikasi tingkat kematangan daun ketapang (*Terminalia catappa*) menggunakan metode *transfer learning*. Sistem dirancang dalam bentuk pipeline yang terstruktur mulai dari proses pengumpulan dataset hingga menghasilkan model klasifikasi yang mampu

mengidentifikasi tingkat kematangan daun secara otomatis.

Gambar 3.1 menunjukkan rancangan sistem yang digunakan dalam penelitian. Proses diawali dengan pengumpulan dataset daun ketapang yang terdiri atas tiga kelas, yaitu daun muda, daun menguning, dan daun tua. Dataset kemudian melalui tahap *preprocessing* dan augmentasi data sebelum dipisahkan menjadi data pelatihan (*training set*) dan data validasi (*validation set*).

Selanjutnya dilakukan pengujian menggunakan tiga skenario eksperimen, yaitu MobileNetV2 sebagai *feature extractor*, MobileNetV2 dengan metode *partial fine-tuning*, dan ResNet50 sebagai model pembanding. Hasil dari setiap skenario dievaluasi menggunakan beberapa metrik performa, yaitu *accuracy*, *precision*, *recall*, *F1-score*, dan *confusion matrix*. Model dengan performa terbaik kemudian digunakan sebagai sistem klasifikasi tingkat kematangan daun ketapang [8].

B. Dataset dan Akuisisi Data

Dataset yang digunakan dalam penelitian ini terdiri dari sekitar 2.418 citra daun ketapang (*Terminalia catappa*) yang diperoleh secara mandiri melalui proses pengambilan gambar langsung di lapangan. Seluruh citra diambil pada kondisi pencahayaan alami untuk memperoleh variasi karakteristik visual yang mendekati kondisi penggunaan sebenarnya.

Proses akuisisi data dilakukan menggunakan tiga perangkat smartphone yang berbeda, yaitu:

Tabel 3.1 Spesifikasi Perangkat Akuisisi Dataset

Parameter	Samsung Galaxy A50s	Samsung Galaxy A33 5G	Realme 12 5G
Resolusi Kamera Utama	48 MP	48 MP	108 MP (Mode Standar 48 MP)
Aperture	f/2.0	f/1.8	f/1.75
Panjang Fokus	26 mm	26 mm	24 mm
Format Citra	JPEG / JPG	JPEG / JPG	JPEG / JPG
Kondisi Pengambilan	Outdoor	Outdoor	Outdoor
Jarak Objek	15–25 cm	15–25 cm	15–25 cm

Penggunaan tiga perangkat yang berbeda

bertujuan untuk meningkatkan keberagaman karakteristik citra yang diperoleh selama proses pengumpulan dataset. Perbedaan sensor kamera, aperture, dan karakteristik pemrosesan citra pada masing-masing perangkat menghasilkan variasi warna, kontras, dan pencahayaan yang berbeda. Dengan demikian, model yang dilatih diharapkan memiliki kemampuan generalisasi yang lebih baik terhadap variasi data yang ditemui pada kondisi nyata.

Pembagian dataset dilakukan menggunakan rasio 80% untuk data pelatihan dan 20% untuk data validasi dengan nilai random seed sebesar 42 untuk menjaga konsistensi hasil eksperimen [9].

C. Preprocessing dan Augmentasi Data

Tahap preprocessing dilakukan untuk memastikan seluruh citra memiliki format yang sesuai dengan kebutuhan model deep learning. Seluruh gambar diubah ukurannya menjadi 224×224 piksel menggunakan metode interpolasi bilinear agar kompatibel dengan dimensi masukan MobileNetV2 [10].

Setelah proses resizing, dilakukan normalisasi menggunakan fungsi *preprocess_input* bawaan MobileNetV2. Fungsi ini mengubah rentang nilai piksel dari [0,255] menjadi [-1,1] sehingga proses pelatihan model menjadi lebih stabil dan konvergensi dapat dicapai lebih cepat.

Untuk meningkatkan kemampuan generalisasi model serta mengurangi risiko overfitting, diterapkan teknik augmentasi data secara dinamis selama proses pelatihan. Teknik augmentasi yang digunakan meliputi random horizontal flip, random vertical flip, random rotation dengan faktor 0,3, random zoom sebesar 20%, random brightness sebesar 20%, dan random contrast sebesar 20% [11].

Penerapan augmentasi memungkinkan model memperoleh variasi citra yang lebih beragam tanpa perlu melakukan pengambilan data tambahan secara langsung di lapangan.

D. Konfigurasi Transfer Learning dan Skenario Eksperimen

Tabel 3.2 Skenario beberapa Arsitektur

Skenario	Arsitektur	Strategi Pelatihan	Learning Rate
A	MobileNetV2	Feature Extractor (Frozen Layer)	1×10^{-3}

B	MobileNetV2	Partial Fine-Tuning (Unfreeze Top 30 Layer)	1×10^{-4}
C	ResNet50	Fine-Tuning (Unfreeze Top 30 Layer)	1×10^{-5}

Penelitian ini menggunakan tiga skenario eksperimen yang berbeda untuk mengevaluasi pengaruh strategi transfer learning dan pemilihan arsitektur terhadap performa klasifikasi tingkat kematangan daun ketapang. Perbedaan utama dari setiap skenario terletak pada mekanisme pelatihan, jumlah lapisan yang dilatih ulang, serta nilai learning rate yang digunakan selama proses optimasi model.

1. Skenario A: MobileNetV2 Feature Extractor

Skenario A digunakan sebagai baseline penelitian dengan memanfaatkan MobileNetV2 sebagai feature extractor. Pada skenario ini seluruh lapisan dasar (base layer) MobileNetV2 yang telah dilatih menggunakan dataset ImageNet dibekukan (frozen) sehingga bobot model tidak mengalami perubahan selama proses pelatihan. Pelatihan hanya dilakukan pada lapisan klasifikasi yang ditambahkan pada bagian akhir jaringan.

Pendekatan ini bertujuan untuk mengukur kemampuan fitur bawaan MobileNetV2 dalam mengenali karakteristik visual daun ketapang tanpa melakukan penyesuaian terhadap bobot backbone model. Optimasi model dilakukan menggunakan algoritma Adam dengan learning rate sebesar 1×10^{-3} .

2. Skenario B: MobileNetV2 Partial Fine-Tuning

Skenario B merupakan konfigurasi utama yang digunakan dalam penelitian ini. Berbeda dengan Skenario A, pendekatan yang diterapkan adalah partial fine-tuning dengan membuka kembali 30 lapisan terakhir MobileNetV2 untuk dilatih ulang menggunakan dataset daun ketapang [12].

Proses pelatihan dilakukan dalam dua tahap. Tahap pertama menggunakan MobileNetV2 sebagai feature extractor dengan seluruh lapisan backbone dibekukan. Setelah model mencapai kondisi stabil, 30 lapisan terakhir dibuka kembali (unfreeze) dan dilakukan proses fine-tuning menggunakan learning rate sebesar 1×10^{-4} .

Strategi ini memungkinkan model mempertahankan kemampuan ekstraksi fitur umum dari ImageNet sekaligus beradaptasi dengan karakteristik visual spesifik daun ketapang.

3. Skenario C: ResNet50 Fine-Tuning

Skenario C digunakan sebagai model pembanding dengan memanfaatkan arsitektur ResNet50. Pemilihan ResNet50 dilakukan karena arsitektur ini memiliki jumlah parameter yang lebih besar dan sering digunakan pada berbagai penelitian klasifikasi citra [13].

Proses pelatihan dilakukan menggunakan dua tahap yang serupa dengan Skenario B. Pada tahap pertama seluruh lapisan backbone dibekukan dan hanya classifier head yang dilatih. Selanjutnya 30 lapisan terakhir ResNet50 dibuka kembali untuk dilakukan fine-tuning menggunakan learning rate sebesar 1×10^{-5} .

Pada seluruh skenario eksperimen digunakan struktur classifier head yang sama untuk menjaga konsistensi proses perbandingan model. Classifier head terdiri atas lapisan Global Average Pooling, Dense Layer dengan 128 neuron dan fungsi aktivasi ReLU, serta Dense Output Layer dengan tiga neuron dan fungsi aktivasi Softmax untuk menghasilkan prediksi kelas daun muda, daun menguning, dan daun tua.

IV. HASIL DAN PEMBAHASAN

A. Hasil Pelatihan Model

Proses pelatihan model dilakukan menggunakan pendekatan transfer learning dengan tiga skenario eksperimen yang berbeda, yaitu MobileNetV2 sebagai Feature Extractor (Skenario A), MobileNetV2 dengan Partial Fine-Tuning (Skenario B), dan ResNet50 Fine-Tuning sebagai model pembanding (Skenario C).

Setiap skenario menggunakan mekanisme Early Stopping dengan parameter patience sebesar 7 epoch untuk memantau nilai validation accuracy. Apabila tidak terjadi peningkatan akurasi selama 7 epoch berturut-turut, proses pelatihan dihentikan secara otomatis untuk mencegah terjadinya overfitting.

Tabel 4.1 Perbandingan Hasil Pelatihan dan Konvergensi Multi-Skenario

Parameter Eksperimen	Skenario A (Feature Extractor)	Skenario B (Partial Fine-Tuning)	Skenario C (ResNet50 Fine-Tuning)
Arsitektur Jaringan	MobileNet V2	MobileNet V2	ResNet50
Kondisi Layer Base	Frozen (154 Layer)	Unfreeze Top 30 Layer	Unfreeze Top 30 Layer
Learning Rate	1×10^{-3}	$1 \times 10^{-3} \rightarrow 1 \times 10^{-4}$	$1 \times 10^{-3} \rightarrow 1 \times 10^{-5}$
Jumlah Fase Pelatihan	1 Fase	2 Fase	2 Fase
Epoch Konvergensi	11 Epoch	26 Epoch	20 Epoch
Validation Loss	0,0200	0,0027	0,0012
Validation Accuracy	99,79%	100,00%	100,00%

Berdasarkan Tabel 4.1, Skenario B menghasilkan performa terbaik dengan nilai validation accuracy sebesar 100,00% dan validation loss sebesar 0,0027. Hasil tersebut menunjukkan bahwa penerapan Partial Fine-Tuning pada 30 lapisan terakhir MobileNetV2 mampu meningkatkan kemampuan model dalam mengenali karakteristik visual daun ketapang dibandingkan pendekatan Feature Extractor.

Skenario A menghasilkan validation accuracy sebesar 99,79%. Meskipun seluruh lapisan backbone dibekukan, performa yang diperoleh tetap sangat tinggi. Hal ini menunjukkan bahwa fitur dasar yang dipelajari MobileNetV2 dari dataset ImageNet masih relevan untuk digunakan pada klasifikasi tingkat kematangan daun ketapang.

Sementara itu, Skenario C yang menggunakan ResNet50 juga mencapai validation accuracy sebesar 100,00%. Namun, arsitektur ini membutuhkan jumlah parameter dan waktu komputasi yang lebih besar dibandingkan MobileNetV2. Oleh karena itu, MobileNetV2 dengan strategi Partial Fine-Tuning dipilih sebagai model utama karena memberikan keseimbangan terbaik antara akurasi dan efisiensi komputasi [14].

B. Evaluasi Model

Model terbaik yang diperoleh dari Skenario B selanjutnya dievaluasi menggunakan data validasi yang telah dipisahkan secara otomatis sebesar 20% dari total dataset. Evaluasi

dilakukan menggunakan metrik precision, recall, dan F1-score untuk mengukur kemampuan model dalam melakukan klasifikasi pada setiap kelas daun.

Tabel 4.2 Hasil Evaluasi Model pada Data Validasi

Kelas Daun	Precision	Recall	F1-Score	Support
Daun Muda	100%	100%	100%	151
Daun Menguning	100%	100%	100%	158
Daun Tua	100%	100%	100%	174
Rata-rata	100%	100%	100%	483

Berdasarkan Tabel 4.2, model berhasil mengklasifikasikan seluruh data validasi dengan sangat baik. Nilai precision, recall, dan F1-score mencapai 100% pada seluruh kelas, menunjukkan bahwa model mampu mengenali setiap kategori daun secara konsisten tanpa menunjukkan kecenderungan bias terhadap salah satu kelas tertentu.

Jumlah data validasi yang digunakan terdiri dari 151 citra daun muda, 158 citra daun menguning, dan 174 citra daun tua. Seluruh data tersebut tidak pernah digunakan selama proses pelatihan sehingga dapat digunakan untuk mengevaluasi kemampuan model dalam melakukan prediksi pada data yang belum pernah dilihat sebelumnya.

Keberhasilan model dalam mencapai performa tinggi dipengaruhi oleh perbedaan karakteristik visual antar kelas yang cukup jelas. Daun muda didominasi warna hijau, daun menguning menunjukkan fase transisi antara hijau dan kuning, sedangkan daun tua memiliki warna cokelat kemerahan yang lebih dominan [15], [16].

Meskipun model mencapai akurasi yang sangat tinggi pada data validasi, hasil tersebut tetap perlu diinterpretasikan secara hati-hati. Tingginya performa dapat dipengaruhi oleh distribusi data yang relatif seimbang serta karakteristik visual yang cukup berbeda antar kelas. Oleh karena itu, pengujian pada dataset eksternal dengan kondisi lingkungan yang lebih beragam masih diperlukan untuk mengevaluasi kemampuan generalisasi model secara lebih luas.

C. Analisis Confusion Matrix

Analisis confusion matrix dilakukan untuk mengetahui distribusi prediksi yang dihasilkan

oleh model pada setiap kelas daun. Selain digunakan untuk mengukur jumlah prediksi yang benar, confusion matrix juga dapat menunjukkan pola kesalahan klasifikasi yang terjadi pada masing-masing skenario eksperimen [17].

Tabel 4.3.1 Confusion Matrix Skenario A (*Feature Extractor*)

Aktual / Prediksi	Daun Muda	Daun Menguning	Daun Tua
Daun Muda	151	0	0
Daun Menguning	0	158	0
Daun Tua	0	1	173

Tabel 4.3. 2 Confusion Matrix Skenario B (*Partial Fine-Tuning*)

Aktual / Prediksi	Daun Muda	Daun Menguning	Daun Tua
Daun Muda	151	0	0
Daun Menguning	0	158	0
Daun Tua	0	0	174

Tabel 4.3.3 Confusion Matrix Skenario C (*ResNet50 Fine-Tuning*)

Aktual / Prediksi	Daun Muda	Daun Menguning	Daun Tua
Daun Muda	151	0	0
Daun Menguning	0	158	0
Daun Tua	0	0	174

Pada Skenario A ditemukan satu kesalahan klasifikasi, yaitu satu citra daun tua yang diprediksi sebagai daun menguning. Kesalahan ini menunjukkan bahwa tanpa proses fine-tuning, model masih mengalami kesulitan dalam membedakan beberapa karakteristik visual yang berada pada fase transisi kematangan daun.

Sebaliknya, Skenario B dan Skenario C berhasil mengklasifikasikan seluruh data validasi dengan benar sehingga menghasilkan akurasi sebesar 100%. Hasil tersebut menunjukkan bahwa proses fine-tuning memberikan kontribusi yang signifikan dalam meningkatkan kemampuan model untuk mengenali fitur spesifik yang terdapat pada daun ketapang.

D. Komparasi dengan Penelitian Terdahulu

Untuk mengetahui posisi penelitian terhadap penelitian sebelumnya, dilakukan komparasi dengan beberapa penelitian yang menggunakan pendekatan deep learning pada permasalahan klasifikasi citra daun.

Tabel 4. 3 Komparasi dengan Penelitian Terdahulu

Penelitian	Objek	Metode	Hasil
Klasifikasi Daun Ecoprint	Klasifikasi daun ecoprint	MobileNetV2 & ResNet50	Klasifikasi daun menggunakan transfer learning (Jutif)
Identifikasi Penyakit Tanaman	Penyakit daun tanaman	MobileNetV2	Akurasi tinggi untuk deteksi penyakit daun (Webology)
Deteksi Penyakit Daun Penelitian yang sedang dilakukan	Penyakit tanaman Kematangan Daun Ketapang	Improved MobileNetV2 MobileNetV2 + Partial Fine-Tuning	Akurasi 99,53% (PMC) 99,79%–100,00%

menunjukkan bahwa MobileNetV2 merupakan salah satu arsitektur yang banyak digunakan pada berbagai permasalahan klasifikasi citra daun dan tanaman. Pada penelitian ini, MobileNetV2 dikombinasikan dengan strategi Partial Fine-Tuning pada 30 lapisan terakhir untuk meningkatkan kemampuan model dalam mengenali karakteristik visual daun ketapang

V. KESIMPULAN

Penelitian ini berhasil mengembangkan sistem klasifikasi tingkat kematangan daun ketapang (*Terminalia catappa*) berbasis citra digital menggunakan metode *transfer learning*. Sistem yang dibangun mampu mengklasifikasikan daun ketapang ke dalam tiga kategori, yaitu daun muda, daun menguning, dan daun tua berdasarkan karakteristik visual yang terdapat pada citra.

Untuk memperoleh konfigurasi model yang optimal, dilakukan pengujian menggunakan tiga skenario eksperimen, yaitu MobileNetV2 sebagai *Feature Extractor*, MobileNetV2 dengan *Partial Fine-Tuning*, dan ResNet50 sebagai model pembanding. Hasil pengujian menunjukkan bahwa strategi *Partial Fine-Tuning* pada 30 lapisan terakhir MobileNetV2 memberikan performa terbaik dengan *validation accuracy* mencapai 100,00% dan *validation loss* sebesar 0,0027. Sementara itu, Skenario A menghasilkan *validation accuracy* sebesar 99,79%, sedangkan Skenario C menggunakan ResNet50 juga mencapai 100,00%.

Hasil evaluasi terhadap data validasi menunjukkan bahwa model terbaik mampu mencapai nilai *precision*, *recall*, dan *F1-score* sebesar 100% pada seluruh kelas daun. Analisis *confusion matrix* menunjukkan bahwa model mampu melakukan klasifikasi secara konsisten dengan tingkat kesalahan yang sangat rendah. Hasil tersebut menunjukkan bahwa penerapan *transfer learning* menggunakan MobileNetV2 dengan strategi *Partial Fine-Tuning* efektif untuk mengenali tingkat kematangan daun ketapang berdasarkan citra digital.

Selain menghasilkan performa yang sangat baik, MobileNetV2 juga memiliki kebutuhan komputasi yang relatif ringan dibandingkan ResNet50. Dengan demikian, arsitektur MobileNetV2 dinilai lebih efisien dan berpotensi untuk diterapkan pada sistem klasifikasi berbasis perangkat bergerak maupun aplikasi berbasis web.

REFERENSI

- [1] F. Zhuang *et al.*, “A Comprehensive Survey on Transfer Learning,” *Proceedings of the IEEE*, vol. 109, no. 1, pp. 43–76, Jan. 2021, doi: 10.1109/JPROC.2020.3004555.
- [2] J. Lu, X. Liu, X. Ma, J. Tong, and J. Peng, “Improved MobileNetV2 crop disease identification model for intelligent agriculture,” *PeerJ Comput. Sci.*, vol. 9, p. e1595, Sep. 2023, doi: 10.7717/peerj-cs.1595.
- [3] H. dac Hung *et al.*, “Chemical constituents from the leaves of *Terminalia catappa* L. (Combretaceae),” *Vietnam J. Sci. Technol.*, vol. 60, no. 4, pp. 625–630, Aug. 2022, doi: 10.15625/2525-2518/15972.
- [4] C. Shorten and T. M. Khoshgoftaar, “A survey on Image Data Augmentation for Deep Learning,” *J. Big Data*, vol. 6, no. 1, p. 60, Dec. 2019, doi: 10.1186/s40537-019-0197-0.
- [5] A. Perko, O. Trapp, E. Maul, F. Röckel, A. Piltaver, and S. Vršič, “Monitoring and Genotyping of Wild Grapevine (*Vitis vinifera* L. subsp. *sylvestris*) in Slovenia,” *Plants*, vol. 13, no. 9, p. 1234, Apr. 2024, doi: 10.3390/plants13091234.
- [6] K. Cheng, S. Gao, W. Dong, X. Yang, Q. Wang, and H. Yu, “Boosting label weighted extreme learning machine for classifying multi-label imbalanced data,” *Neurocomputing*, vol. 403, pp. 360–370, Aug. 2020, doi: 10.1016/j.neucom.2020.04.098.
- [7] D. B. V. T. Devvret Verma, “Plant Leaf Disease Detection Using Mobilenetv2,” *Webology*, pp. 3241–3246, 2021, doi: 10.29121/WEB/V18I5/60.
- [8] S. Hajar, M. Murinto, and A. Yudhana, “Comparison of Transfer Learning Strategies Using MobileNetV2 and ResNet50 for Ecoprint Leaf Classification,” *Jurnal Teknik Informatika (Jutif)*, vol. 6, no. 5, pp. 3251–3264, Oct. 2025, doi: 10.52436/1.jutif.2025.6.5.5266.
- [9] Y. Huang, D. Ye, J. Yang, W. Zhu, L. Li, and Y. Ding, “Dual recognition elements for selective determination of progesterone based on molecularly imprinted electrochemical aptasensor,” *Anal. Chim. Acta*, vol. 1264, p. 341288, Jul. 2023, doi: 10.1016/j.aca.2023.341288.
- [10] D. B. , V. T. Devvret Verma, “Plant Leaf Disease Detection Using Mobilenetv2,” *Webology*, pp. 3241–3246, 2021, doi: 10.29121/WEB/V18I5/60.
- [11] A. Buslaev, V. I. Iglovikov, E. Khvedchenya, A. Parinov, M. Druzhinin, and A. A. Kalinin, “Albumentations: Fast and Flexible Image Augmentations,” *Information*, vol. 11, no. 2, p. 125, Feb. 2020, doi: 10.3390/info11020125.
- [12] J. Ahmmed, M. Rana, F. Ahmed, M. Hasan, and R. Hasan Shohan, “Fine-Tuned CNN-Based Approach for Multi-Class Mango Leaf Disease Detection.”
- [13] S. Hajar, M. Murinto, and A. Yudhana, “Comparison of Transfer Learning Strategies Using MobileNetV2 and ResNet50 for Ecoprint Leaf Classification,” *Jurnal Teknik Informatika (Jutif)*, vol. 6, no. 5, pp. 3251–3264, Oct. 2025, doi: 10.52436/1.jutif.2025.6.5.5266.
- [14] D. M. W. Powers and Ailab, “EVALUATION: FROM PRECISION, RECALL AND F-MEASURE TO ROC, INFORMEDNESS, MARKEDNESS & CORRELATION.”
- [15] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, IEEE, Jun. 2020, pp.

- 770–778. doi: 10.1109/CVPR.2016.90.
- [16] W. Jin, H. Zhang, and Z. Ming, “Optimal bipartite consensus for discrete-time multi-agent systems with event-triggered mechanism based on adaptive dynamic programming,” *Neurocomputing*, vol. 564, p. 126965, Jan. 2024, doi: 10.1016/j.neucom.2023.126965.
- [17] G. Zeng, “Invariance Properties and Evaluation Metrics Derived from the Confusion Matrix in Multiclass Classification,” *Mathematics*, vol. 13, no. 16, p. 2609, Aug. 2025, doi: 10.3390/math13162609.